

Apprentissage de bibliothèque défaisable : des méthodes typées à contrats d'exécution qui se désapprennent à la dérive

Nathanael Braun

2026

Préprint v1 — rapport de système / d'expérience

Résumé

Les agents fondés sur de grands modèles de langage réutilisent leur travail passé via une mémoire floue — recherche (RAG), raisonnement à partir de cas, bibliothèques de compétences — qui rappelle par similarité de surface et n'a aucune notion d'une prémisse devenue fausse. Lorsque le monde dérive d'une manière qui ne change pas la requête, ces mémoires continuent de servir une réponse périmée. Nous présentons l'**apprentissage de bibliothèque défaisable** : une bibliothèque apprise de méthodes typées et composables, chacune dotée d'un **contrat d'exécution défaisable**. Une méthode est supposée à la composition, vérifiée à l'exécution, et — lorsque sa postcondition induite échoue — rétractée avec attribution de blâme (un désapprentissage de type JTMS), après quoi la bibliothèque est révisée, non jetée. La structure typée qui rend une méthode canonicalisable rend aussi sa réutilisation amortissable et sa composition vérifiable sur les seuls contrats, à contexte par appel borné. Sur un moteur réel à base de règles, cohérent par maintien de la vérité (JTMS), en isolant chaque mécanisme : (E2) sous une invalidation de prémisse externe en cours de flux, les mémoires par rappel seul servent du périmé, tandis que tout cache doté d'un crochet d'invalidation récupère — ce qu'un contrat typé déclaratif ajoute à un rappel codé à la main, c'est une éviction sélective et principielle, plus la généralité et la sûreté de composition (confirmé sur modèle réel) ; (E1) le transfert structurel inter-problèmes est correct et gratuit sur des instances apparentées tenues à l'écart, tandis que l'ablation sans transformation est non saine, et le seul nombre d'appels ne permet pas de les distinguer ; (E3) une vérification de composition en boîte fermée coïncide avec le résultat en boîte ouverte sur chaque paire évaluée (aucun faux-admis), chacune des trois barrières de sûreté étant porteuse ; (P4) l'amortissement est un gradient de la fraction canonicalisable, avec sûreté à chaque couverture et non-sûreté au-delà. Aucun mécanisme n'est nouveau (JTMS, contrats à blâme, apprentissage de bibliothèque, révision de théorie, logique de séparation) ; la contribution est leur composition en une bibliothèque apprise de méthodes typées qui réalise un désapprentissage principal et sélectif à la dérive — ce que les mémoires par rappel seul ne font pas — bornée par un plafond K1 mesuré.

1 Introduction

Un agent qui résout de nombreux problèmes apparentés devrait devenir moins coûteux et plus fiable avec le temps. La voie dominante consiste à mémoriser et rappeler : stocker des solutions ou compétences passées, retrouver la plus proche, la réutiliser ou l'adapter. La génération augmentée par recherche [16], le raisonnement à partir de cas et les bibliothèques de compétences comme Voyager [27] partagent cette forme et le même angle mort : ils rappellent par similarité de *surface* et ne représentent pas une *prémisse devenue fausse*. Quand le monde change d'une manière qui

ne change **pas** la requête — une réglementation se durcit, un fait est audité et trouvé faux, une politique est révoquée — la réponse en cache reste le plus proche voisin, et elle est toujours servie. Les bibliothèques statiques (programmes appris, compétences distillées [11, 4]) ont le problème inverse : saines à l'apprentissage, elles ne savent pas *désapprendre*.

L'ingrédient manquant est un **contrat typé défaisable** sur chaque unité réutilisable. Empruntant aux contrats logiciels avec blâme [14] et à la vérification graduelle [3], une méthode déclare ce qu'elle lit, écrit, exige et garantit, sur un alphabet de faits *typé*. Pour une méthode *apprise* la garantie est une hypothèse induite : **supposée à la composition, vérifiée à l'exécution, rétractée avec blâme** en cas de violation — une opération de maintien de la vérité [8, 7] — après quoi la bibliothèque est révisée en *spécialisant* la précondition fautive, non en la supprimant (révision de théorie [19, 23] ; révision de croyances [1]). La même structure typée rend la réutilisation **amortissable** (une clé canonique stable) et la composition **vérifiable sans ouvrir la boîte** [18, 22]. Le tout est borné par une unique contrainte honnête, K1 : seule la structure typée, canonicalisable, amortit ; la prose véritable reste dans le modèle.

Nous employons *apprentissage de bibliothèque* au sens de DreamCoder/Stitch [11, 4] (induire des méthodes typées réutilisables par abstraction [21]), non un ajustement statistique ; on pourrait parler d'*induction de méthodes*. La nouveauté n'est **pas** l'induction mais le **contrat défaisable** qui permet de *désapprendre* une méthode induite. Le changement est de flot de contrôle : là où une mémoire par similarité fait *requête* → *retrouver* → *réutiliser*, la nôtre fait *requête* → *retrouver-le-contrat* → *vérifier* → *exécuter* → *contrôler* → *rétracter* → *spécialiser*. Le suffixe contrôler-et-rétracter est ce que les expériences isolent.

Contributions. (1) Le cadrage des méthodes d'agent réutilisables comme **non-terminaux typés à deux faces dotés d'un contrat d'exécution défaisable**, et la boucle supposer/vérifier/rétracter-blâmer/réviser. (2) Une évaluation reproductible, isolant les mécanismes, sur un moteur réel — la mémoire par rappel seul ne peut pas désapprendre tandis qu'un contrat typé déclaratif récupère la dérive *sélectivement, généralement, sûrement-en-composition* (E2, simu + réel, avec une référence Invalidant équitable) ; transfert structurel sain que le seul nombre d'appels ne certifie pas (E1) ; aucun faux-admis sur les compositions évaluées, chacune des trois barrières ablée (E3) ; amortissement en gradient de la fraction canonicalisable (P4) — en explicitant ce que chaque expérience établit ou non.

2 Approche

2.1 L'objet : une méthode à deux faces

Une **méthode** est, pour son appelant, une boîte noire à contrat typé ; à l'intérieur, des *productions* la réalisent (séquence, branchement, map, fold). Formellement, un non-terminal de remplacement d'hyperarêtes [15, 9] à sélection conditionnée par précondition [12]. Nous tenons deux régimes séparés par *intention de conception* (nous ne prouvons pas la décidabilité ici) : la **grammaire des méthodes** est *censée* rester décidable via un rang de montage bien fondé et des invariants de typage — l'existence d'un plan HTN récursif est indécidable en général [13] — tandis que l'**exécution** sur des données de taille d'exécution est une couche explicitement bornée par budget, Turing-complète. Le lien à la logique monadique du second ordre [6] est une motivation, non un théorème établi ici.

2.2 Le contrat : un triplet de séparation défaisable

Une méthode déclare une empreinte de lecture, une empreinte d'écriture, une précondition, une postcondition et une étiquette d'effet. La composition sous état partagé est le problème du cadre [17] ; nous le levons par une discipline d'empreintes de logique de séparation [18, 22] sur l'alphabet typé fini. Pour une méthode *apprise* la postcondition est une hypothèse induite : **supposée à la composition, vérifiée à la stabilisation, rétractée avec blâme** [14, 3]. Le moniteur d'exécution est le JTMS [8], donnant une sûreté *éventuelle* (non statique) — précisément le désapprentissage qui manque aux références.

2.3 Pipeline et le plancher K1

Une formulation est typée en un but ; une méthode est sélectionnée et composée sur contrats ; les cas la traversent ; les traces distillent (anti-unification [21] ; filtrées par MDL [11, 4]) en de nouvelles méthodes typées ; la dérive rétracte. Le repli universel est le *plancher de micro-tâches* : tout ce qui ne se réduit pas à une méthode typée en cache se réduit à une micro-tâche qu'un petit modèle traite aisément. Un contrat *manquant* coûte un appel modèle bon marché ; un contrat *faux* est rattrapé par la vérification d'exécution — jamais une erreur silencieuse.

3 Mise en œuvre

Tous les mécanismes sont réalisés sur un moteur existant de graphe de faits typés à base de règles, cohérent par JTMS, à concepts déclaratifs et stabilisation par chaînage avant, sans modification du cœur hormis une option de requête additive. La clé de mémorisation typée est le condensé de canonicalisation du moteur ; le vérificateur de contrat défaisable (entailment à la composition sur domaines abstraits, assertion de postcondition à l'exécution, trois barrières de sûreté) et la transformation de transfert structurel (relativiser-au-stockage / lier-au-rejeu) sont des bibliothèques hôtes. Un exécuteur de cas durable à l'échelle est un artefact connu (un réseau de workflow [26] sur un magasin durable, dans la lignée d'AWS Step Functions Distributed Map [2], du cache de contenu de Prefect, et de DBOS [25]) ; notre vue-croyance se situe au-dessus. Le cycle de vie défaisable — **supposer** → **vérifier** → **contrôler** → **rétracter** → **spécialiser** — correspond un-à-un aux fonctions du moteur :

```
select(but): # SUPPOSER (a la composition)
  M <- bibliotheque.match(but.faits_typed) # cle typee ; un echec -> plancher de micro-taches
  supposer M.contrat # checkCompose: post(prec) |= pre(M); escalade, jamais faux-admis

apply(M, cas): # VERIFIER + CONTROLER (a l'execution)
  cle <- digest(cas.premisse_typee) # cle canonique K1
  si memo.has(cle): retourner memo[cle] # amortir un cas type recurrent
  sortie <- run(M, cas) # sinon derivier (appel modele / sous-graphe)
  si non assertPost(M.contrat, sortie): # la post tient ? + G1 cadre + G2 oracle-d'effet
    quarantaine(cas); blamer(M.contrat) # ne jamais valider une mauvaise sortie
    retourner
  memo[cle] <- sortie; retourner sortie

on ingest(fait): # RETRACTER + SPECIALISER (derive)
  pour e dans memo dependant de fait: # JTMS: re-verifier chaque post affectee
    si non satisfies(e.contrat.post, e.faits + {fait}):
      retracter(e); blamer(e.contrat) # desapprendre: evincer + attribuer le blame
  bibliotheque.reviser(blame): pre <- specialiser(pre) # reviseOnBlame (CEGIS): restreindre, sans
    supprimer
```

4 Expériences

4.1 Dispositif

Les expériences utilisent les mécanismes réels du moteur à deux fidélités explicites. **E1 et E3 instancient le moteur complet** (graphe + stabilisation + JTMS) ; **E2, P4 et E5 isolent les fonctions** réelles (*digest*, *satisfies*, *canonValue*) depuis un banc, sans la boucle complète — nous ne prétendons pas qu’E2 exerce la rétractation JTMS native (il la ré-implémente sur le même prédicat réel). Le modèle est un **simulateur déterministe** (oracle parfait de la règle *courante* étant donné seulement ce que révèle l’invite — toute péremption/coût vient du mécanisme, non d’une erreur modèle) ou un **modèle local réel** (*qwen36-q2-vram*). Chaque exécution est conditionnée par un **auto-test du banc** (sous le simulateur le bras naïf doit être parfait, sinon avortement). Sept bras partagent une interface : Naïf, Long-contexte, RAG, CBR (clé typée, sans re-vérification), Compétence (prose), **Invalidant** (cache à clé typée + rappel grossier codé à la main : crochet d’invalidation, sans contrat typé), et **Struct** (la bibliothèque typée au contrat défaisable). L’Invalidant sépare « possède une invalidation » de « possède un contrat typé ».

4.2 E2 — défaisance à la dérive

Un domaine d’approbation typé ($N=80$, deux classes auditées ; l’exécution réelle utilise $N=48$, une classe) avec une invalidation de prémisses *externe* en cours de flux : un audit de conformité marque une classe non conforme, faisant basculer ses cas approuvés vers le refus. L’audit n’est **pas un champ d’enregistrement**, donc un cache par rappel seul retrouve le même enregistrement et sert sa réponse pré-audit (Table 1).

bras	appels	exact.	exact. dérive	ctx max
Struct (contrat typé)	26	1.00	1.00	290
Invalidant (crochet, sans contrat)	28	1.00	1.00	290
Naïf	80	1.00	1.00	290
Long-contexte	80	1.00	1.00	2062
RAG	48	0.95	0.00	290
CBR (clé typée, sans re-vérif.)	24	0.95	0.00	290
Compétence (prose)	80	0.95	0.00	297

Table 1: E2 (simu). Les bras par rappel seul (RAG/CBR/Compétence) servent du périmé ; Invalidant et Struct récupèrent.

La lecture est triple. Les **mémoires par rappel seul servent du périmé** — le rappel seul ne récupère pas, l’audit n’entrant jamais dans leur chemin de réutilisation. La **récupération exige un mécanisme d’invalidation**, et l’Invalidant comme Struct en ont un (exactitude-dérive 1.00). Ce que le **contrat défaisable typé ajoute au rappel codé à la main** : (i) la *sélectivité* — Struct re-vérifie la post par entrée (*satisfies*) et n’évince que les 2 classes *violées* (approve), là où le rappel jette des classes entières (4 entrées) et paie les re-dérivations supplémentaires (26 vs 28 appels) ; (ii) la *généralité* ; (iii) la *sûreté de composition* (§4.4). L’exécution réelle (*qwen36-q2-vram*, $N=48$) reproduit ceci : RAG/CBR/Compétence 0.00 ; Invalidant 14 appels / 1.00 ; Struct 13 appels / 2.8 s / 1.00 / ctx 278 vs Long-contexte 1304. L’affirmation défendable n’est pas « seul Struct récupère » mais « la mémoire par rappel seul ne sait pas désapprendre, et un contrat typé déclaratif fournit la récupération de façon sélective, générale et sûre en composition ».

4.3 E1 — amortissement et transfert structurel

Un domaine de décomposition structurelle (une méthode qui *crée* un sous-graphe avec des identifiants), sur le moteur complet. Partition : entraînement, apparentés tenus à l'écart, nouveau tenu à l'écart. C'est un contrôle d'**existence-et-sûreté sur un petit ensemble** (2 apparentés, 1 nouveau), **pas un taux** : avec la transformation relativiser/liar, *toutes* les instances apparentées transfèrent à 0 appel et **sainement**, le nouveau paie (pas de faux rejeu), totaux 3 appels contre 5. L'ablation sans transformation « touche » mais rejoue le *mauvais espace d'identifiants* — **non sain**. **Seule la vérification de sûreté** distingue une réutilisation saine d'un rejeu erroné ; le seul nombre d'appels les classe à égalité. (Un *taux* de transfert sur de nombreuses méthodes est un travail futur.)

4.4 E3 — sûreté de composition

En composant des paires sur leurs seuls contrats typés (boîte fermée) et en comparant au résultat moteur (moteur complet), la décision **coïncide avec la réalité sur chaque paire évaluée, sans faux-admis** — le vérificateur n'accepte jamais à tort ; les paires sous-déterminées ou hors-fragment *escaladent*. C'est montré sur un petit ensemble construit (3 paires sain/non-sain/escalade ; une 4^e ajoute l'oracle) : une **démonstration d'existence**, pas un taux de population. Chaque barrière est porteuse sur un exemple : retirer la complétude de cadre manque une écriture non déclarée ; retirer l'étiquette d'effet admet un effet externe non vérifié ; retirer la détection de cycle admet un cycle couplé rétractable. La décision ne lit que l'empreinte partagée ; le vérificateur (entailment par domaines abstraits, sain-mais-incomplet) est l'artefact le plus développé, plutôt sous-évalué ici. (Un corpus plus grand, non trié à la main, est un travail futur.)

4.5 P4 — le plafond de couverture K1

Sur une charge mixte (fraction p entièrement typée ; le reste portant un composant en prose qui prime sur la règle typée), l'appartenance à K1 décidée par la **vraie** barrière de canonicalisation, l'amortissement est un **gradient en couverture** (approbation : $0 \rightarrow 19 \rightarrow 44 \rightarrow 69 \rightarrow 94\%$; tri : $0 \rightarrow 22 \rightarrow 47 \rightarrow 72 \rightarrow 97\%$). L'exactitude de Struct est 1.00 à chaque couverture — la fraction non typée est un *coût* de micro-tâche, jamais une *falaise* de sûreté. Une variante gloutonne mémorisant les enregistrements en prose sur leur clé typée chute à une exactitude égale à la fraction propre : amortir au-delà de K1 est non sain. Nous sommes explicites : c'est une **illustration construite**, pas une mesure réelle — nous *fixons* p et *définissons* les enregistrements en prose pour primer, donc « non sain au-delà de K1 » découle par construction. Elle établit la *forme* et la sûreté à chaque niveau ; la fraction canonicalisable d'un corpus réel est dépendante du domaine et non mesurée ici.

4.6 E5 — coût de bookkeeping à l'échelle du flux

Un contrôle de coût de bookkeeping, pas une affirmation sur le passage à l'échelle de la partie difficile : sur un espace typé de 200 classes avec un audit, quand la longueur du flux N croît de $1,320 \rightarrow 20,320$ (l'ensemble des classes est fixe ; aucune méthode nouvelle, aucun modèle), Table 2.

Les appels de Struct restent constants ($\rightarrow$ appels/ $N \rightarrow 0$ tandis que Naïf reste à un) ; la bibliothèque est bornée par le nombre de classes (trivialement) ; une dérive ne rétracte que les classes invalidées ($O(\text{invalidé})$: 2 sur 200). Coûts par opération : canonicalisation $\approx 0,5\text{--}3,5\mu\text{s}$ /appel (l'écart = chauffe JIT), une passe d'éviction $\approx 0,5$ ms. Le contenu honnête est étroit : le bookkeeping typé n'est pas le goulet. Il ne teste **pas** l'échelle dans la dimension qui compte (bibliothèque croissante de méthodes *distinctes*, corpus réel, modèle réel sur tous les bras) — travail futur.

N	appels Struct	appels/ N	appels Naïf	bibliothèque	évincés
1,320	202	0,153	1,320	200	2
5,320	202	0,038	5,320	200	2
20,320	202	0,010	20,320	200	2

Table 2: E5. Les appels de Struct restent constants ; bibliothèque bornée par l’ensemble (fixe) des classes ; éviction sélective.

5 Travaux apparentés

Recherche et mémoire de cas. RAG [16] et CBR rappellent par similarité ; ils ne représentent pas une *prémisse devenant invalide* (E2). Les bibliothèques de compétences (Voyager [27]) stockent de la *prose* sans prémisse défaisable.

Mémoire des agents LLM. MemGPT/Letta [20], Reflexion [24], GraphRAG [10] gèrent *quoi* garder/rappeler finement, mais par pertinence/récence/similarité ; aucun ne représente une prémisse typée dont la falsification rétracte une réutilisation. Ils sont complémentaires : un contrat défaisable pourrait s’y placer comme couche de rétractation.

Apprentissage de bibliothèque. DreamCoder [11] et Stitch [4] font croître une bibliothèque par abstraction [21] ; sans contrat d’exécution défaisable.

Contrats, blâme, vérification graduelle. [14, 3] sont la lignée de notre discipline, appliquée aux méthodes *appries*.

Composition. Non-terminal HRG à deux faces [15, 9, 6] à sélection HTN [12] ; plan HTN récursif indécidable [13] ; composition saine via empreintes de séparation [18, 22], problème du cadre [17] (E3).

Révision de théorie/croyances (le voisin le plus proche). *reviseOnBlame* relève de la révision de théorie d’une base de règles *apprise* : EITHER [19] et FORTE [23] révisent des théories Horn sur contre-exemples ; la révision d’un ensemble de croyances est l’AGM [1]. Notre apport est opérationnel : attacher la révision à une bibliothèque de méthodes *typée, composable, canonicalisable*.

Maintien de la vérité. Un JTMS [8, 7].

Exécution durable / IVM. Un cas est un marquage 1-sûr sur un réseau de workflow [26] ; l’exécuteur durable est un artefact connu [2, 25]. DBSP [5]/Materialize maintiennent des *valeurs* ; nous ne revendiquons pas la nouveauté pour *recupérer* sur dérive — la différence est que notre invalidation est *dérivée d’un contrat déclaratif* (re-vérifier la post ; blâmer ; spécialiser).

6 Menaces à la validité

Simulateur vs réel. Le simulateur retire l’erreur du modèle pour isoler le *mécanisme* ; l’E2 réel confirme l’ordre. Le simulateur ne prédit pas l’exactitude absolue en réel ; exécuter plus de bras en réel est un travail futur.

K1-couverture paramétrée. P4 *fixe* la fraction typée ; les affirmations non circulaires sont la *forme* (un gradient), l’universalité de la sûreté, et la non-sûreté de l’amortissement glouton. La fraction absolue d’une charge de production est dépendante du domaine.

Force des références. RAG/CBR/Compétence sont nos implémentations ; le bras Invalidant isole « possède un crochet » de « possède un contrat typé », d’où l’affirmation précise. Une RAG/CBR à invalidation-événementielle ajustée est essentiellement l’Invalidant.

Nouveauté / positionnement. Aucun mécanisme n’est nouveau ; le travail est une *composition*. Nous le positionnons comme une unification opérationnelle, non un nouvel algorithme.

Échelle et étendue. Mécanismes à N modeste sur deux domaines synthétiques ; E5 est un coût de bookkeeping. Un corpus réel et un face-à-face contre les mémoires d’agents modernes restent des travaux futurs.

Sûreté éventuelle, non statique. L’applicabilité d’une méthode apprise est indécidable en général (Rice) ; la garantie est une sûreté éventuelle via un moniteur d’exécution porteur au-dessus d’une barrière saine-incomplète.

Moteur unique / auteur unique. Une reproduction indépendante renforcerait les affirmations structurelles.

7 Conclusion

La mémoire par rappel seul ne sait pas désapprendre ; les bibliothèques statiques sont saines mais figées. Une bibliothèque apprise de méthodes typées dotée d’un **contrat d’exécution défaisable** obtient les deux : elle amortit et compose sur la structure typée, et lorsqu’une prémisses dérive elle *rétracte avec blâme et révisé* — récupérant l’exactitude là où la recherche, le CBR et les bibliothèques de compétences servent du périmé. Nos expériences l’isolent : le rappel seul ne récupère pas ; un crochet d’invalidation le peut ; un contrat typé *déclaratif* fournit cette récupération de façon sélective, générale et sûre-en-composition, à contexte borné, sur un moteur réel et confirmé en réel — borné par une fraction canonicalisable elle-même frontière de sûreté. Chaque mécanisme relève de l’état de l’art ; la contribution est leur composition en une représentation typée unique où amortissement, vérification de composition et désapprentissage coïncident. C’est, délibérément, une synthèse d’ingénierie avec une propriété émergente testable — un désapprentissage principal et sélectif — plutôt qu’un nouvel algorithme.

Code & reproductibilité. Le moteur et un artefact d’expérience autonome sont publics sur github.com/9pings/skynet-graph — `artifact/paper-d11/` avec la suite déterministe `tests/integration/paper` (npm test). L’E2 en réel utilise un endpoint local compatible OpenAI. Sous licence AGPL-3.0-or-later.

Références

- [1] C. E. Alchourrón, P. Gärdenfors, D. Makinson. On the Logic of Theory Change. *J. Symbolic Logic* 50(2):510–530, 1985.
- [2] AWS. Step Functions Distributed Map. 2022.
- [3] J. Bader, J. Aldrich, É. Tanter. Gradual Program Verification. *VMCAI* 2018, LNCS 10747:25–46.
- [4] M. Bowers et al. Top-Down Synthesis for Library Learning. *POPL* 2023; PACMPL 7(POPL).
- [5] M. Budiu et al. DBSP: Automatic Incremental View Maintenance for Rich Query Languages. *PVLDB* 16(7):1601–1614, 2023.
- [6] B. Courcelle. The Monadic Second-Order Logic of Graphs I. *Inf. Comput.* 85(1):12–75, 1990.
- [7] J. de Kleer. An Assumption-based TMS. *Artificial Intelligence* 28(2):127–162, 1986.

- [8] J. Doyle. A Truth Maintenance System. *Artificial Intelligence* 12(3):231–272, 1979.
- [9] F. Drewes, H.-J. Kreowski, A. Habel. Hyperedge Replacement Graph Grammars. In *Handbook of Graph Grammars* Vol. 1, World Scientific, 95–162, 1997.
- [10] D. Edge et al. From Local to Global: A Graph RAG Approach to Query-Focused Summarization. arXiv:2404.16130, 2024.
- [11] K. Ellis et al. DreamCoder. *PLDI* 2021.
- [12] K. Erol, J. Hendler, D. S. Nau. UMCP: A Sound and Complete Procedure for HTN Planning. *AIPS* 1994.
- [13] K. Erol, J. Hendler, D. S. Nau. Complexity Results for HTN Planning. *Ann. Math. AI* 18:69–93, 1996.
- [14] R. B. Findler, M. Felleisen. Contracts for Higher-Order Functions. *ICFP* 2002, 48–59.
- [15] A. Habel. Hyperedge Replacement: Grammars and Languages. LNCS 643, Springer, 1992.
- [16] P. Lewis et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *NeurIPS* 2020.
- [17] J. McCarthy, P. J. Hayes. Some Philosophical Problems from the Standpoint of AI. *Machine Intelligence* 4, 1969.
- [18] P. W. O’Hearn, J. C. Reynolds, H. Yang. Local Reasoning about Programs that Alter Data Structures. *CSL* 2001, LNCS 2142:1–19.
- [19] D. Ourston, R. J. Mooney. Theory Refinement Combining Analytical and Empirical Methods. *Artificial Intelligence* 66(2):273–309, 1994.
- [20] C. Packer et al. MemGPT: Towards LLMs as Operating Systems. arXiv:2310.08560, 2023.
- [21] G. D. Plotkin. A Note on Inductive Generalization. *Machine Intelligence* 5:153–163, 1970.
- [22] J. C. Reynolds. Separation Logic. *LICS* 2002, 55–74.
- [23] B. L. Richards, R. J. Mooney. Automated Refinement of First-Order Horn-Clause Domain Theories. *Machine Learning* 19(2):95–131, 1995.
- [24] N. Shinn et al. Reflexion: Language Agents with Verbal Reinforcement Learning. *NeurIPS* 2023.
- [25] A. Skiadopoulos et al. DBOS: A DBMS-oriented Operating System. *PVLDB* 15(1):21–30, 2022.
- [26] W. M. P. van der Aalst. The Application of Petri Nets to Workflow Management. *J. Circuits, Systems and Computers* 8(1):21–66, 1998.
- [27] G. Wang et al. Voyager: An Open-Ended Embodied Agent with Large Language Models. arXiv:2305.16291, 2023.